Plan your trip with Kayak

Bloc 1 : Construction et alimentation d’une infrastructure de gestion de données

Julien Jorge

Octobre 2026

Le projet

L'équipe marketing de Kayak souhaite une application qui recommande à ses utilisateurs où partir en vacances, à partir de données réelles sur la météo et sur les hôtels disponibles. Au départ, aucune donnée n'existe : notre travail consiste à les collecter, à les stocker dans un data lake, puis à les nettoyer et à les charger dans une base de données pour qu'elles soient exploitables.

Le périmètre est limité aux 35 destinations françaises choisies par l'équipe marketing. Le résultat attendu est un classement des cinq destinations où la météo des prochains jours est la plus favorable, et pour chacune une sélection d'hôtels, le tout présenté sur deux cartes.

Ce projet est réalisé dans le cadre de la certification Concepteur Développeur en Science des Données de Jedha, bloc 1 : construction et alimentation d'une infrastructure de gestion de données.

Les données

Aucune donnée n’a été fournie : tout a été collecté par le code, auprès de trois sources.

- **Nominatim** (OpenStreetMap) : un service de géocodage gratuit, qui transforme le nom de chaque destination en coordonnées GPS. Nous en tirons la latitude, la longitude et l’adresse complète des 35 destinations.
- **OpenWeather** (API One Call) : les prévisions météo à 7 jours pour chaque destination. Nous en calculons trois indicateurs : le cumul de pluie, la température moyenne en journée et la couverture nuageuse moyenne. Les valeurs utilisées ont été relevées le 3 septembre 2026.
- **Booking.com** : pour chacune des cinq destinations retenues, les 25 hôtels de la première page de résultats, soit 125 hôtels. Pour chacun : le nom, l’adresse de sa page Booking, ses coordonnées, sa note et sa description. Cette collecte est faite par scraping, les autres par appel d’API.

Comment ça marche

Tout le travail est dans le notebook, en sept étapes :

1. **Géocodage** : les 35 destinations sont transformées en coordonnées GPS avec Nominatim.
2. **Météo et score** : les prévisions à 7 jours sont récupérées pour chaque destination, puis combinées en un score de beau temps. Les cinq meilleurs scores donnent le Top-5, affiché sur une première carte.
3. **Collecte des hôtels** : une spider Scrapy récupère 25 hôtels par destination du Top-5 sur Booking.com.
4. **Nettoyage** : les données sont mises en forme en deux tables, les destinations et les hôtels, reliées par l'identifiant de destination.
5. **Data lake** : les fichiers bruts et les fichiers nettoyés sont déposés dans un bucket S3, dans deux dossiers séparés.
6. **Entrepôt de données** : les deux tables sont créées puis chargées dans une base PostgreSQL hébergée sur Amazon RDS.
7. **Exploitation** : une requête SQL sur l'entrepôt donne le Top-20 des hôtels, affiché sur une seconde carte.

Les choix importants du projet

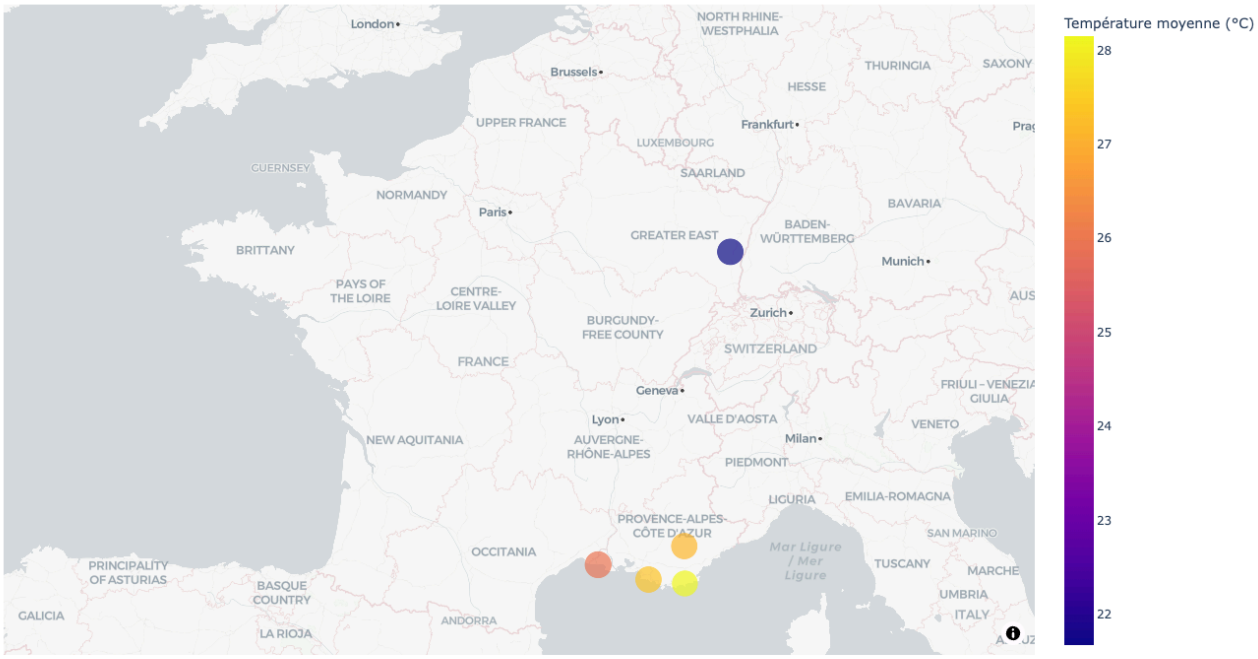
- **La règle de beau temps.** L'énoncé ne la définit pas. Nous avons construit un score sur trois indicateurs, pondérés selon leur importance pour un touriste : la pluie pour moitié, l'écart à une température idéale de 22 °C pour 30 %, la couverture nuageuse pour 20 %.
- **Le contournement de la protection anti-robots de Booking.** Le site ne sert ses pages qu'à un navigateur ayant résolu une épreuve JavaScript. Nous ouvrons donc la page dans un navigateur, qui résout l'épreuve, puis nous relevons le jeton qu'il a obtenu pour le donner à la spider. Cela suffit pour cinq requêtes.
- **Des collectes jouées une seule fois.** La météo change chaque jour et le jeton Booking expire. Chaque étape de collecte recharge donc son fichier s'il existe déjà, au lieu de rappeler la source : le Top-5 et les hôtels restent cohérents d'une exécution à l'autre.

Les résultats

Les cinq destinations retenues, pour la semaine suivant le 3 septembre 2026 :

Destination	Pluie sur 7 jours (mm)	Température moyenne (°C)	Nuages (%)	Score
Saintes Maries de la mer	0,2	25,9	28	0,82
Château du Haut Koenigsbourg	2,9	21,7	64	0,79
Cassis	0,0	27,3	25	0,79
Gorges du Verdon	0,0	27,1	29	0,79
Bormes les Mimosas	0,0	28,2	24	0,76

Quatre des cinq destinations sont dans le Sud-Est ; le Château du Haut Koenigsbourg s'y glisse grâce à une température proche des 22 °C visés, malgré un ciel plus couvert.



Les cinq destinations retenues, colorées par température moyenne

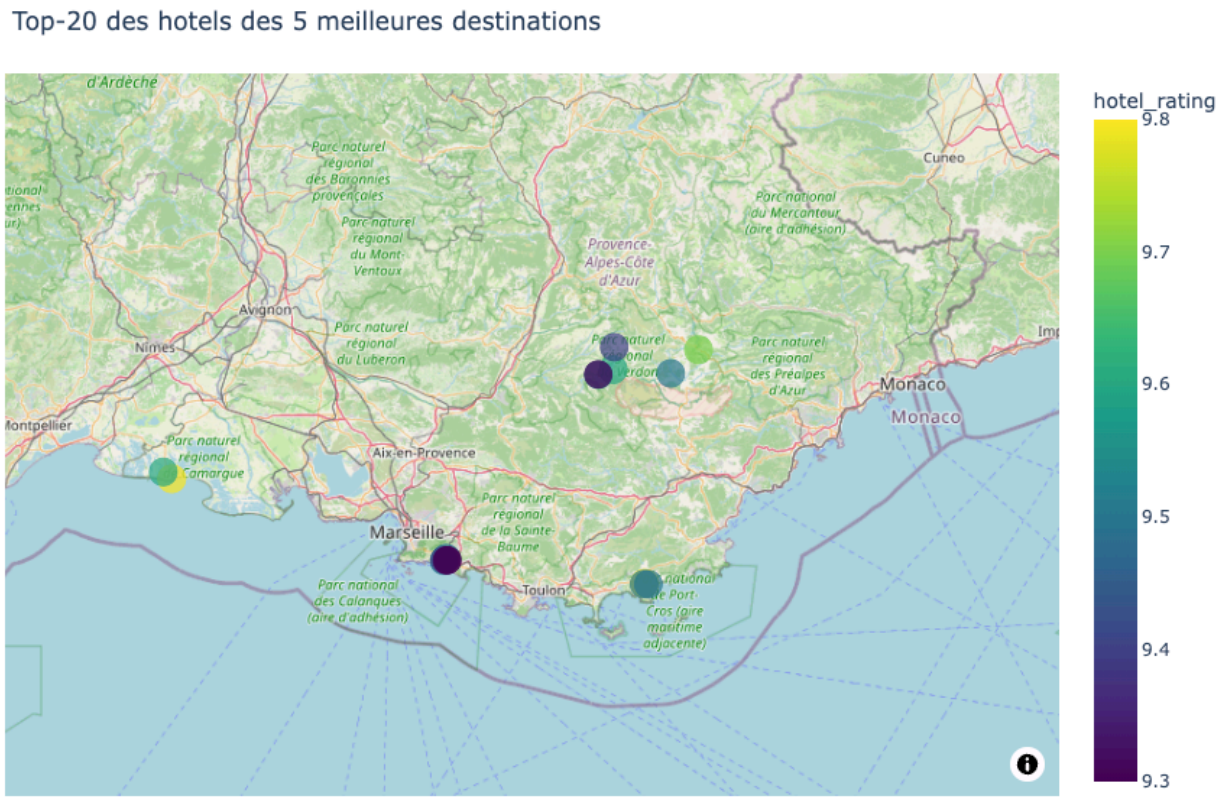
Pour ces cinq destinations, 125 hôtels ont été collectés, dont 2 sans note. Le Top-20 des hôtels, obtenu par une requête sur l'entrepôt, regroupe les hôtels notés de 9,3 à 9,8 sur 10.

Les deux tables de l'entrepôt :

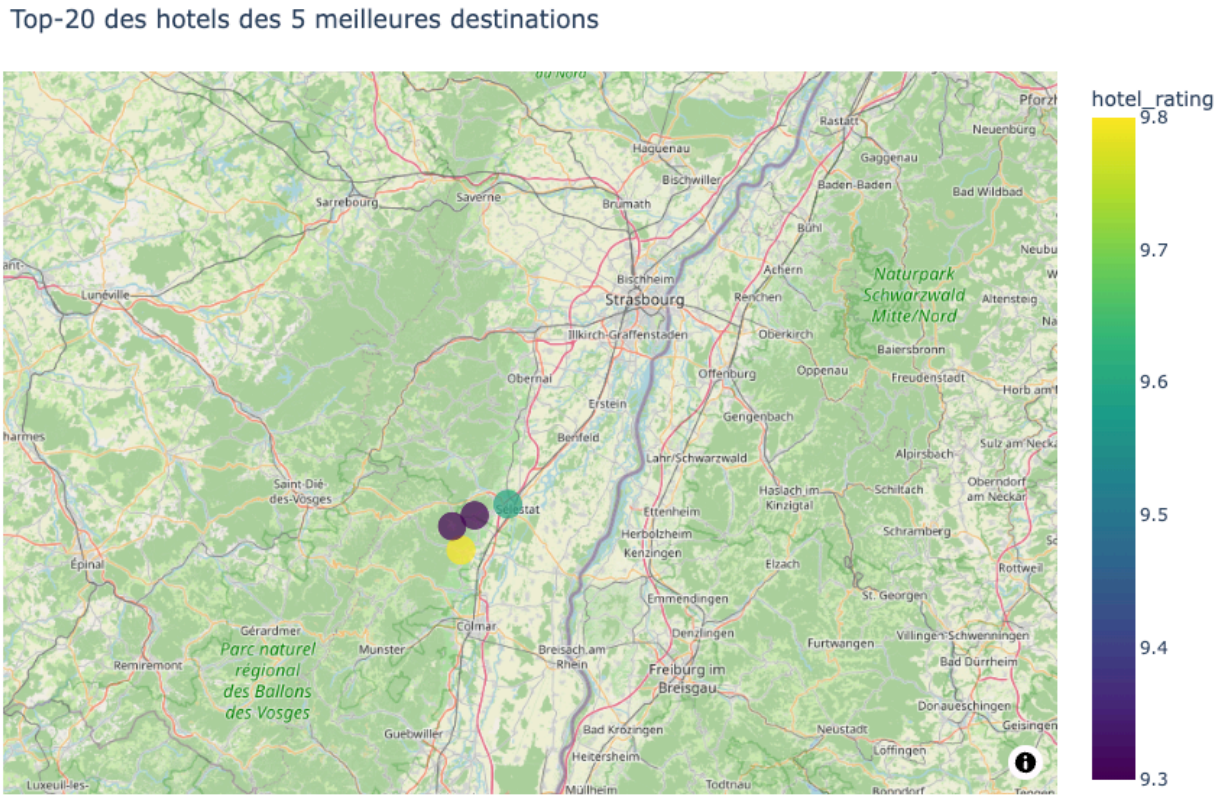
- **cities** : 35 lignes, une par destination, avec ses coordonnées, ses trois indicateurs météo et son score ;

- **hotels** : 125 lignes, une par hôtel, rattachée à sa destination par une clé étrangère.

Les deux cartes sont interactives dans le notebook, en fin d'étape 2 et en fin d'étape 7 ; la seconde est reproduite ici en deux vues, le Sud-Est et l'Alsace.



Le Top-20 des hôtels, vue sur le Sud-Est



Le Top-20 des hôtels, vue sur l’Alsace

Exécuter le projet

Contenu du dépôt

```
kayak/
├── 01-Plan_your_trip_with_Kayak.ipynb   le notebook, livrable principal
├── src/booking_spider.py                la spider Scrapy pour Booking.com
├── data/processed/                      les fichiers produits par le notebook
├── .env.example                         la liste des variables à renseigner
└── README.md
```

Prérequis

- Python 3.13 avec les bibliothèques pandas, requests, scrapy, boto3, sqlalchemy, psycopg, plotly et python-dotenv.
- Un compte AWS avec un bucket S3, une instance PostgreSQL sur RDS et un utilisateur IAM autorisé à écrire dans le bucket. Ces ressources sont créées à la main dans la console AWS : le notebook les alimente, il ne les crée pas.
- Une clé d'API OpenWeather (offre One Call).

Configuration

Copier le fichier .env.example en .env et renseigner chaque variable. Le fichier indique pour chacune où trouver sa valeur. Le fichier .env contient des secrets : il n'est pas versionné et ne doit jamais l'être.

Lancement

Ouvrir le notebook et exécuter toutes les cellules, depuis la racine du projet.

Les fichiers de data/processed/ sont fournis : les trois collectes (géocodage, météo, hôtels) ne sont pas relancées, et le notebook s'exécute en moins d'une minute. Pour recollecter, supprimer le fichier concerné dans data/processed/. Attention pour les hôtels : il faut au préalable relever un jeton Booking valide, comme expliqué dans le notebook, et une nouvelle collecte météo change le Top-5, donc les destinations pour lesquelles il faut collecter les hôtels.

Limites et suites possibles

- **Une météo figée.** Le classement repose sur les prévisions du 3 septembre 2026. Une vraie application recollecterait la météo chaque jour et recalculerait le Top-5.
- **Un jeton Booking à renouveler à la main.** La collecte des hôtels dépend d'un jeton relevé dans un navigateur, qui expire en quelques heures. Elle ne peut donc pas être automatisée telle quelle.
- **25 hôtels par destination, sans tri.** Ce sont ceux de la première page de résultats de Booking, dans son ordre. Une version plus complète parcourrait plusieurs pages et filtrerait selon des critères (prix, type d'hébergement).
- **Des pondérations choisies à la main.** Les poids du score (50 % pluie, 30 % température, 20 % nuages) relèvent du bon sens. Une version aboutie les calibrerait sur des données réelles de réservation.
- **Un volume modeste.** 35 destinations et 125 hôtels tiennent dans une base PostgreSQL classique. Pour toute la France ou l'Europe, il faudrait un entrepôt conçu pour l'analyse de gros volumes, comme Amazon Redshift, et paralléliser les collectes.